Creating AI Applications Using Python

Practical Assignments

Базове опрацювання тексту з використанням NLTK

Бізнес-контекст

Компанія Feedback Insight аналізує клієнтські відгуки, щоб розуміти, які слова найчастіше трапляються в позитивних і негативних коментарях.
Ваше завдання — підготувати текстові дані для аналізу: очистити їх, розбити на слова, нормалізувати і виділити ключові терміни.

Завдання 1

Підготуйте дані для аналізу.

- Створіть невеликий набір із 5-7 речень (наприклад, відгуки про продукт).
- Очистіть текст від пунктуації та приведіть до нижнього регістру.
- Розділіть текст на токени (слова) за допомогою nltk.word_tokenize.
- Підрахуйте загальну кількість токенів і виведіть перші 10.

Завдання 2

Застосуйте лематизацію та стеммінг.

- Завантажте WordNetLemmatizer і PorterStemmer з бібліотеки NLTK.
- Перетворіть усі токени на леми і на стеми.
- Порівняйте перші 10 вихідних слів, їхні леми та стеми в таблиці. Наприклад, так:

Початкове слово	Лемма	Стем
example	Example	exampl
...	...	...

Завдання 3

Видаліть стоп-слова і проаналізуйте частотність.

- Завантажте список англійських стоп-слів nltk.corpus.stopwords.words('english').
- Видаліть із токенів усі стоп-слова.
- Підрахуйте частоту слів, що залишилися, за допомогою collections.Counter.
- Виведіть 10 найчастіших слів та їхню кількість.

Завдання 4

Робота з корпусами NLTK.

- Завантажте корпус movie_reviews з NLTK.
- Виберіть 5 випадкових відгуків і виведіть перші 20 токенів із кожного.
- Визначте, які слова частіше зустрічаються в позитивних, а які — у негативних відгуках.
- Збережіть результати аналізу в CSV-файл *review_tokens.csv* зі стовпчиками:

Категорія	Слово	Частота

© STEP IT Academy, itstep.org

All the copyrighted photos, audio, and video works, fragments of which are used in the material, are the property of their respective owners. Fragments of the works are used for illustrative purposes to the extent justified by the objective, within the educational process, and for educational purposes, in accordance with the Act of “On Copyright and Related Rights”. The scope and method of the cited works are in accordance with the adopted norms, without prejudice to the normal exploitation of copyright, and do not prejudice the legitimate interests of authors and right holders. At the time of use, the cited works fragments cannot be replaced by alternative, non-copyrighted counterparts and meet the criteria for fair use. All rights reserved. Any reproduction of the materials or its part is prohibited. Use of the works or their fragments must be agreed upon with authors and rights holders. Agreed material use is only possible with reference to the source. Responsibility for unauthorized copying and commercial use of the material is determined by the current legislation.